

FACULTE DES SCIENCES  
DEPARTEMENT D'INFORMATIQUE

## Filière Ingénierie des Systèmes Intelligents (ISI)

### Projet : Vision par ordinateur

Semestre 3 : 2025/2026

*Réalisé par :*

**El Akkaoui Adam & Zaidouh Mohammed**

Intitulé

**Traduction de la langue  
des signes en texte**



# **Résumé**

La langue des signes constitue un moyen de communication essentiel pour les personnes sourdes et malentendantes. Toutefois, l'absence d'interopérabilité entre la langue des signes et le langage écrit ou parlé représente un obstacle important à l'inclusion sociale et professionnelle. Dans ce contexte, les avancées récentes en intelligence artificielle, notamment en vision par ordinateur et en apprentissage profond, offrent des solutions prometteuses pour l'automatisation de la reconnaissance des gestes.

Ce projet propose la conception et l'implémentation d'un système de traduction automatique des lettres de la langue des signes américaine (ASL) en texte, basé sur un réseau de neurones convolutionnel (CNN). Le modèle est entraîné sur le dataset ASL Alphabet, composé de 29 classes correspondant aux lettres de l'alphabet ainsi qu'à des gestes spécifiques. Les images sont prétraitées en niveaux de gris et encodées en format catégoriel afin d'entraîner un modèle de classification multi-classes optimisé à l'aide de l'algorithme Adam et de la fonction de perte categorical cross-entropy.

L'architecture développée comporte trois couches convolutionnelles suivies de couches entièrement connectées, totalisant plus de deux millions de paramètres. Les résultats obtenus démontrent une bonne capacité de classification sur l'ensemble de test, ainsi qu'une performance satisfaisante en temps réel via une application webcam développée avec OpenCV.

Ce travail met en évidence l'efficacité des réseaux convolutionnels pour la reconnaissance de gestes statiques et constitue une base solide pour le développement futur de systèmes plus avancés de traduction continue de la langue des signes.

# Table des matières

|             |                                              |           |
|-------------|----------------------------------------------|-----------|
| <b>I.</b>   | <b>Contexte, Problématique et Objectifs</b>  | <b>7</b>  |
| 1.          | Contexte général                             | 7         |
| 2.          | Problématique                                | 7         |
| 3.          | Objectifs du projet                          | 7         |
| 4.          | Contribution du projet                       | 8         |
| <b>II.</b>  | <b>État de l'art</b>                         | <b>8</b>  |
| 1.          | Introduction                                 | 8         |
| 2.          | Approches traditionnelles                    | 8         |
| 3.          | Approches basées sur l'apprentissage profond | 9         |
| 4.          | Datasets existants                           | 9         |
| 5.          | Limites et défis des approches existantes    | 10        |
| 6.          | Conclusion                                   | 10        |
| <b>III.</b> | <b>Méthodologie et pipeline du projet</b>    | <b>10</b> |
| 1.          | Introduction                                 | 10        |
| 2.          | Description du dataset                       | 10        |
| 3.          | Prétraitement des données                    | 11        |
| 4.          | Conception du modèle CNN                     | 11        |
| 5.          | Entraînement du modèle                       | 11        |
| 6.          | Évaluation et validation                     | 12        |
| 7.          | Intégration en temps réel                    | 12        |
| 8.          | Conclusion                                   | 12        |
| <b>IV.</b>  | <b>Architecture et Implémentation</b>        | <b>12</b> |
| 1.          | Introduction                                 | 12        |
| 2.          | Architecture du modèle CNN                   | 12        |
| 3.          | Paramètres du modèle                         | 14        |
| 4.          | Prétraitement et encodage                    | 14        |
| 5.          | Implémentation pratique                      | 14        |
| 6.          | Schéma du pipeline                           | 14        |
| 7.          | Conclusion                                   | 15        |
| <b>V.</b>   | <b>Résultats et Discussion</b>               | <b>15</b> |
| 1.          | Introduction                                 | 15        |
| 2.          | Évaluation du modèle                         | 15        |
| 3.          | Analyse qualitative                          | 15        |
| i.          | Prédiction de la lettre "A" en temps réel    | 16        |

|        |                                                     |    |
|--------|-----------------------------------------------------|----|
| ii.    | Prédiction de la lettre “B” en temps réel.....      | 16 |
| iii.   | Prédiction de la lettre “C” en temps réel.....      | 17 |
| iv.    | Prédiction de la lettre “D” en temps réel.....      | 17 |
| v.     | Prédiction de la lettre “E” en temps réel.....      | 17 |
| vi.    | Prédiction de la lettre “F” en temps réel.....      | 18 |
| vii.   | Prédiction de la lettre “G” en temps réel.....      | 18 |
| viii.  | Prédiction de la lettre “H” en temps réel.....      | 18 |
| ix.    | Prédiction de la lettre “I” en temps réel.....      | 19 |
| x.     | Prédiction de la lettre “J” en temps réel.....      | 19 |
| xi.    | Prédiction de la lettre “k” en temps réel.....      | 19 |
| xii.   | Prédiction de la lettre “L” en temps réel.....      | 20 |
| xiii.  | Prédiction de la lettre “M” en temps réel.....      | 20 |
| xiv.   | Prédiction de la lettre “N” en temps réel.....      | 20 |
| xv.    | Prédiction de la lettre “O” en temps réel.....      | 21 |
| xvi.   | Prédiction de la lettre “P” en temps réel.....      | 21 |
| xvii.  | Prédiction de la lettre “Q” en temps réel.....      | 21 |
| xviii. | Prédiction de la lettre “R” en temps réel.....      | 22 |
| xix.   | Prédiction de la lettre “S” en temps réel.....      | 22 |
| xx.    | Prédiction de la lettre “T” en temps réel.....      | 22 |
| xxi.   | Prédiction de la lettre “U” en temps réel.....      | 23 |
| xxii.  | Prédiction de la lettre “V” en temps réel.....      | 23 |
| xxiii. | Prédiction de la lettre “W” en temps réel.....      | 23 |
| xxiv.  | Prédiction de la lettre “X” en temps réel.....      | 24 |
| xxv.   | Prédiction de la lettre “Y” en temps réel.....      | 24 |
| xxvi.  | Prédiction de la lettre “Z” en temps réel.....      | 24 |
| xxvii. | Prédiction de classes “spéciaux” en temps réel..... | 25 |
| 4.     | Limitations et difficultés rencontrées.....         | 26 |
| 5.     | Perspectives d’amélioration.....                    | 26 |
| 6.     | Conclusion.....                                     | 26 |

# **Introduction Générale**

L'intelligence artificielle et la vision par ordinateur connaissent aujourd'hui un essor considérable, notamment grâce aux progrès réalisés dans le domaine de l'apprentissage profond. Les réseaux de neurones convolutionnels ont démontré des performances remarquables dans diverses applications telles que la reconnaissance faciale, la détection d'objets, l'analyse médicale ou encore l'interprétation de gestes. Parmi ces domaines d'application, la reconnaissance automatique de la langue des signes représente un enjeu sociétal majeur.

La langue des signes constitue un système linguistique complet, utilisé par des millions de personnes sourdes ou malentendantes à travers le monde. Malgré son importance, elle reste peu accessible aux personnes ne la maîtrisant pas, ce qui crée une barrière de communication significative. Le développement de systèmes intelligents capables de traduire automatiquement les gestes en texte ou en parole pourrait contribuer de manière significative à l'inclusion sociale et professionnelle des personnes concernées.

La reconnaissance de la langue des signes repose sur l'analyse d'informations visuelles complexes, incluant la forme de la main, l'orientation des doigts et la configuration spatiale du geste. Ces caractéristiques peuvent varier en fonction de l'éclairage, de la position ou de l'arrière-plan, rendant la tâche particulièrement difficile. Les approches traditionnelles basées sur l'extraction manuelle de caractéristiques ont montré leurs limites face à cette variabilité. En revanche, les méthodes basées sur l'apprentissage profond permettent d'apprendre automatiquement des représentations discriminantes à partir des données brutes.

Dans ce contexte, le présent projet vise à concevoir et implémenter un système de traduction des lettres de la langue des signes américaine (ASL) en texte à l'aide d'un réseau de neurones convolutionnel. Le système développé comprend l'entraînement d'un modèle de classification d'images, son évaluation sur un ensemble de test, ainsi que son intégration dans une application de reconnaissance en temps réel via webcam.

Ce travail s'inscrit dans le cadre du module de Vision par Ordinateur du Master en Ingénierie des Systèmes Intelligents et met en pratique les concepts fondamentaux liés au traitement d'images, à l'apprentissage supervisé et aux architectures profondes. L'objectif est non seulement d'obtenir un modèle performant, mais également d'analyser son architecture, sa complexité et ses limites afin de proposer des pistes d'amélioration futures.

# **I. Contexte, Problématique et Objectifs**

## **1. Contexte général**

La communication est un élément fondamental de l'interaction humaine et constitue un pilier essentiel de l'intégration sociale et professionnelle. Pour les personnes sourdes et malentendantes, la langue des signes représente un moyen naturel et structuré de communication. Elle repose sur un ensemble de gestes, de positions et de mouvements des mains, accompagnés d'expressions faciales et corporelles, permettant d'exprimer des idées, des émotions et des informations complexes.

Cependant, malgré son importance, la langue des signes n'est pas largement maîtrisée par la population générale. Cette situation crée une barrière de communication significative entre les personnes sourdes et entendant. Dans les contextes administratifs, éducatifs ou professionnels, l'absence d'interprètes spécialisés peut limiter l'accessibilité et l'inclusion.

Avec l'essor des technologies numériques et des systèmes intelligents, il devient envisageable de développer des solutions automatisées capables de traduire les gestes en texte ou en parole. Les progrès récents en vision par ordinateur et en apprentissage profond ont considérablement amélioré la capacité des machines à interpréter des informations visuelles complexes, ouvrant ainsi la voie à des systèmes de reconnaissance automatique de la langue des signes.

## **2. Problématique**

La reconnaissance automatique de la langue des signes constitue un problème complexe relevant de la classification d'images et de l'analyse de formes. Elle nécessite l'identification précise de configurations spécifiques des mains, qui peuvent varier selon plusieurs facteurs tels que l'angle de prise de vue, l'éclairage, l'arrière-plan ou encore les différences morphologiques entre individus.

Dans le cas particulier de la reconnaissance des lettres de la langue des signes, chaque geste correspond à une configuration distincte des doigts et de la paume. Certaines lettres présentent des similitudes visuelles importantes, ce qui rend la tâche de classification plus difficile. De plus, les images capturées en temps réel peuvent contenir du bruit visuel ou des variations d'échelle.

La problématique centrale de ce projet peut donc être formulée comme suit :

Comment concevoir un système basé sur la vision par ordinateur capable de reconnaître automatiquement et avec précision les lettres de la langue des signes à partir d'images, et de les traduire en texte en temps réel ?

Cette problématique implique plusieurs défis techniques, notamment l'extraction de caractéristiques discriminantes, la conception d'un modèle robuste et l'optimisation des performances pour une utilisation en temps réel.

## **3. Objectifs du projet**

L'objectif principal de ce projet est de développer un système intelligent de reconnaissance des lettres de la langue des signes basé sur un réseau de neurones convolutionnel.

Plus précisément, les objectifs peuvent être détaillés comme suit :

Le premier objectif consiste à mettre en place un pipeline complet de traitement d'images, incluant le chargement des données, le prétraitement (conversion en niveaux de gris et formatage des tenseurs) ainsi que l'encodage des labels en représentation catégorielle.

Le second objectif est de concevoir et d'implémenter une architecture de réseau de neurones convolutionnel adaptée à la classification multi-classes des gestes statiques. Cette architecture doit être capable d'extraire automatiquement des caractéristiques pertinentes à partir des images et d'apprendre les différences subtiles entre les différentes lettres.

Le troisième objectif consiste à entraîner et évaluer le modèle sur un dataset dédié, puis à analyser ses performances en termes de précision et de complexité computationnelle.

Enfin, un objectif supplémentaire est d'intégrer le modèle entraîné dans une application temps réel utilisant une webcam, permettant ainsi la reconnaissance instantanée des gestes et leur affichage sous forme textuelle.

## **4. Contribution du projet**

Ce projet contribue à la mise en œuvre pratique des concepts étudiés dans le cadre du module de Vision par Ordinateur et du Master en Ingénierie des Systèmes Intelligents. Il combine des notions de traitement d'images, d'apprentissage supervisé, d'optimisation et de déploiement d'un modèle en environnement réel.

La réalisation d'un système complet, allant de l'entraînement du modèle à son utilisation en temps réel, permet de démontrer la faisabilité d'une solution automatique de traduction des lettres de la langue des signes. Elle constitue également une base solide pour des développements futurs visant la reconnaissance de mots ou de phrases complètes.

# **II. État de l'art**

## **1. Introduction**

La reconnaissance automatique de la langue des signes est un domaine de recherche en plein essor, combinant vision par ordinateur, apprentissage automatique et intelligence artificielle. L'objectif principal est de permettre à des systèmes informatiques de comprendre et de traduire les gestes effectués par les mains en texte ou en parole, facilitant ainsi la communication entre les utilisateurs de la langue des signes et les personnes ne la maîtrisant pas.

Au fil des années, plusieurs approches ont été développées, allant des méthodes traditionnelles basées sur l'extraction manuelle de caractéristiques aux techniques modernes utilisant l'apprentissage profond. L'évolution de ce domaine montre une amélioration constante des performances, notamment grâce à la disponibilité de datasets plus larges et à la puissance croissante des architectures de réseaux de neurones.

## **2. Approches traditionnelles**

Les premières tentatives de reconnaissance des gestes reposaient sur des méthodes classiques de vision par ordinateur. Elles impliquaient l'extraction de caractéristiques manuelles à partir des images, telles que :

- Les descripteurs de contours et de formes, permettant de détecter la silhouette de la main et la position des doigts.

- Les descripteurs HOG (Histogram of Oriented Gradients), utilisés pour capturer la distribution des gradients et les orientations des formes.
- Les descripteurs SIFT (Scale-Invariant Feature Transform), pour identifier des points clés invariants aux transformations d'échelle et de rotation.

Ces caractéristiques étaient ensuite utilisées avec des classificateurs traditionnels, tels que les machines à vecteurs de support (SVM), les k-plus proches voisins (KNN) ou les forêts aléatoires. Bien que ces méthodes aient permis les premiers succès, elles présentaient plusieurs limites : sensibilité aux variations d'éclairage, aux angles de prise de vue, aux arrière-plans complexes et faible capacité de généralisation aux nouveaux utilisateurs ou à des gestes similaires.

### 3. Approches basées sur l'apprentissage profond

Avec l'émergence du deep learning, les réseaux de neurones convolutionnels (CNN) sont devenus la méthode dominante pour la reconnaissance d'images et, par extension, pour la reconnaissance des gestes en langue des signes. Les CNN permettent :

- L'apprentissage automatique de caractéristiques hiérarchiques à partir des images brutes, sans nécessiter d'ingénierie manuelle.
- La détection des motifs locaux et globaux, essentiels pour distinguer des gestes visuellement proches.
- La capacité de généralisation sur de grands ensembles de données.

Certaines architectures combinent les CNN avec des réseaux récurrents (LSTM) afin de gérer les séquences temporelles pour la reconnaissance de gestes dynamiques. Cependant, dans le cadre de la reconnaissance des lettres statiques, un CNN simple reste suffisant et efficace.

Les performances des modèles CNN dépendent fortement de la qualité et de la quantité des données, de la profondeur et de la structure du réseau, ainsi que des techniques d'optimisation et de régularisation utilisées.

### 4. Datasets existants

La disponibilité de datasets publics est un facteur clé dans l'évolution de ce domaine. Parmi les datasets les plus connus :

- ASL Alphabet Dataset : contient des images de lettres de l'alphabet en langue des signes. Chaque lettre est représentée par plusieurs centaines d'images prises dans diverses conditions d'éclairage et de position. Ce dataset est pratique pour les projets de reconnaissance de lettres statiques.
- RWTH-PHOENIX-Weather et Chalearn LAP IsoGD : ces datasets contiennent des gestes plus complexes et des séquences vidéo, souvent utilisés pour la reconnaissance dynamique de phrases ou de mots.
- Autres datasets : plusieurs autres datasets existent pour différentes langues des signes, incluant des gestes uniques, des mots ou des expressions.

Pour ce projet, le ASL Alphabet Dataset a été choisi en raison de sa disponibilité et de sa simplicité, permettant de se concentrer sur la conception du modèle CNN et son intégration en temps réel.

## 5. Limites et défis des approches existantes

Malgré les progrès, plusieurs défis subsistent dans la reconnaissance automatique de la langue des signes :

1. Variabilité des gestes : chaque utilisateur peut réaliser un geste légèrement différemment, ce qui peut dégrader la performance du modèle.
2. Conditions d'éclairage et arrière-plan : les systèmes sont souvent sensibles aux variations de luminosité ou à la présence d'objets en arrière-plan.
3. Complexité des gestes dynamiques : la reconnaissance de mots ou phrases nécessite de traiter des séquences vidéo et non seulement des images statiques.
4. Risque de surapprentissage : les modèles à forte capacité peuvent mémoriser les gestes présents dans le dataset sans généraliser à de nouveaux utilisateurs.

Ces limites motivent la recherche de solutions plus robustes, incluant l'augmentation de données, la normalisation des images, l'utilisation de modèles pré-entraînés et l'optimisation pour l'exécution en temps réel.

## 6. Conclusion

L'état de l'art montre que la reconnaissance automatique de la langue des signes a fortement bénéficié des approches basées sur le deep learning. Pour les lettres statiques, les CNN offrent une solution efficace, capable de capturer les caractéristiques discriminantes des gestes tout en étant utilisable en temps réel. Le choix du dataset approprié et l'adoption de bonnes pratiques de prétraitement et d'optimisation sont essentiels pour atteindre de bonnes performances. Ces éléments constituent la base du projet et justifient le développement d'un pipeline complet de reconnaissance des lettres de la langue des signes en texte.

## III. Méthodologie et pipeline du projet

### 1. Introduction

Ce chapitre présente la méthodologie adoptée pour la réalisation du projet, en détaillant le pipeline complet de reconnaissance des lettres de la langue des signes. L'approche repose sur la combinaison de la vision par ordinateur et des réseaux de neurones convolutionnels (CNN) pour permettre une classification précise des gestes. L'objectif est de construire un système capable de traduire automatiquement des images de gestes en texte, tout en garantissant une exécution en temps réel.

Le pipeline du projet se divise en plusieurs étapes principales : acquisition des données, prétraitement, encodage des labels, conception et entraînement du modèle, évaluation, et intégration en application temps réel.

### 2. Description du dataset

Pour ce projet, le dataset choisi contient des images représentant différentes lettres de la langue des signes. Chaque lettre est représentée par plusieurs centaines d'images, capturées dans différentes conditions d'éclairage et de position, ce qui permet au modèle d'apprendre des variations réalistes.

Le dataset est structuré en deux ensembles :

- Ensemble d'entraînement : utilisé pour l'apprentissage du modèle.
- Ensemble de test : utilisé pour évaluer les performances du modèle après entraînement.

Les images sont fournies en couleur, mais pour simplifier le traitement et réduire la complexité computationnelle, elles ont été converties en niveaux de gris. Cela permet de conserver les informations de forme essentielles tout en diminuant le coût en mémoire et en calcul.

### 3. Prétraitement des données

Le prétraitement des images constitue une étape cruciale pour améliorer la performance du modèle. Il comprend les opérations suivantes :

1. Redimensionnement et normalisation : chaque image est transformée en tenseur 3D correspondant à la hauteur, la largeur et le canal unique (grayscale).
2. Encodage des labels : les lettres sont converties en valeurs numériques grâce à un dictionnaire de correspondance, puis transformées en vecteurs catégoriels (one-hot encoding).
3. Sélection des images : un nombre maximal d'images par classe est utilisé pour éviter le déséquilibre et accélérer l'entraînement.

Ces étapes garantissent que le réseau reçoit des données normalisées et cohérentes, facilitant l'apprentissage.

### 4. Conception du modèle CNN

Le cœur du pipeline repose sur un réseau de neurones convolutionnel adapté à la classification multi-classes. L'architecture comprend :

- Trois couches convolutionnelles, permettant d'extraire automatiquement les caractéristiques spatiales des images (formes et contours des mains).
- Deux couches de pooling, réduisant la dimensionnalité des cartes de caractéristiques tout en conservant les informations importantes.
- Une couche de flattening suivie d'une couche dense intermédiaire avec activation LeakyReLU pour apprendre des représentations complexes.
- Une couche dense finale avec activation softmax, produisant un vecteur de probabilité sur toutes les classes.

Cette architecture permet de traiter efficacement les images statiques des lettres et de distinguer des gestes visuellement proches.

### 5. Entraînement du modèle

L'entraînement du modèle utilise les paramètres suivants :

- Optimiseur : Adam, choisi pour sa capacité à ajuster dynamiquement le taux d'apprentissage et accélérer la convergence.
- Fonction de perte : categorical cross-entropy, adaptée à la classification multi-classes.
- Batch size et nombre d'époques : optimisés pour équilibrer vitesse d'entraînement et précision.

L'ensemble d'entraînement est chargé par lot et le modèle est sauvegardé après chaque phase d'apprentissage. Une attention particulière est portée à la diversité des images utilisées pour éviter le surapprentissage.

## 6. Évaluation et validation

Le modèle est évalué sur l'ensemble de test indépendant pour mesurer sa précision, sa robustesse et sa capacité à généraliser à de nouvelles images. Les métriques observées incluent l'exactitude globale ainsi que la distribution des prédictions par classe. Cette étape permet d'identifier les lettres pour lesquelles le modèle rencontre des difficultés et d'évaluer les besoins en ajustement ou augmentation de données.

## 7. Intégration en temps réel

Pour valider l'application pratique du système, le modèle est intégré dans une application utilisant OpenCV et une webcam.

Le pipeline temps réel fonctionne ainsi :

- a) Capturer l'image de la main depuis la webcam.
- b) Définir un cadre de détection centré sur la main.
- c) Convertir le cadre en niveaux de gris et le prétraiter comme pour l'entraînement.
- d) Prédire la lettre correspondante à l'aide du modèle CNN.
- e) Afficher le résultat sous forme de texte sur l'écran.

Cette approche permet d'obtenir une traduction instantanée des gestes en texte, démontrant la faisabilité du système dans un environnement réel.

## 8. Conclusion

Le pipeline présenté combine les étapes de prétraitement, d'apprentissage et d'intégration en temps réel pour créer un système de reconnaissance de lettres de la langue des signes efficace. L'adoption d'un CNN, associée à un prétraitement rigoureux et à une gestion appropriée des données, constitue la base méthodologique du projet. Ce chapitre fournit les fondations nécessaires pour comprendre l'architecture du modèle et l'analyse des performances qui seront présentées dans les chapitres suivants.

# IV. Architecture et Implémentation

## 1. Introduction

L'objectif de ce chapitre est de présenter en détail l'architecture du modèle développé pour la reconnaissance des lettres de la langue des signes et d'expliquer son implémentation pratique. Il décrit la conception du réseau de neurones convolutionnel, les choix techniques effectués, le rôle de chaque couche, ainsi que les paramètres associés. Ce chapitre inclut également l'intégration du modèle dans un environnement temps réel à l'aide d'une webcam.

## 2. Architecture du modèle CNN

Le modèle utilisé est un réseau de neurones convolutionnel (CNN) conçu pour la classification multi-classes des images représentant les lettres de la langue des signes. L'architecture comprend les éléments suivants :

1. Première couche convolutionnelle :
  - 16 filtres de taille 16×16

- Activation ReLU
  - Permet d'extraire des caractéristiques locales à grande échelle, comme la forme générale de la main.
2. Première couche de pooling :
    - Max pooling de taille 3×3
    - Réduit la dimension des cartes de caractéristiques tout en conservant les informations essentielles.
  3. Deuxième et troisième couches convolutionnelles :
    - Respectivement 32 et 64 filtres de taille 8×8
    - Activation ReLU
    - Ces couches capturent des détails plus fins, tels que la position des doigts ou les contours des gestes.
  4. Deuxième couche de pooling :
    - Max pooling de taille 3×3
    - Diminue encore la dimensionnalité et prépare les données pour les couches entièrement connectées.
  5. Couches entièrement connectées :
    - Flatten : transforme la matrice de caractéristiques en un vecteur linéaire
    - Dense avec 128 neurones et activation LeakyReLU : apprend des combinaisons complexes de caractéristiques
    - Dense finale avec 29 neurones et activation softmax : fournit la probabilité pour chacune des classes correspondant aux lettres du dataset

Cette architecture permet de traiter efficacement les images statiques, en distinguant les lettres visuellement proches tout en maintenant une complexité raisonnable.

| Layer (type)                             | Output Shape         | Param #   |
|------------------------------------------|----------------------|-----------|
| conv2d (Conv2D)                          | (None, 185, 185, 16) | 4,112     |
| max_pooling2d (MaxPooling2D)             | (None, 61, 61, 16)   | 0         |
| conv2d_1 (Conv2D)                        | (None, 54, 54, 32)   | 32,800    |
| conv2d_2 (Conv2D)                        | (None, 47, 47, 64)   | 131,136   |
| max_pooling2d_1 (MaxPooling2D)           | (None, 15, 15, 64)   | 0         |
| flatten (Flatten)                        | (None, 14400)        | 0         |
| batch_normalization (BatchNormalization) | (None, 14400)        | 57,600    |
| dense (Dense)                            | (None, 128)          | 1,843,328 |
| leaky_re_lu (LeakyReLU)                  | (None, 128)          | 0         |
| dense_1 (Dense)                          | (None, 29)           | 3,741     |

### 3. Paramètres du modèle

Le modèle totalise 2 072 717 paramètres, dont :

- Paramètres entraînaables : 2 043 917
- Paramètres non entraînaables : 28 800

Ces valeurs montrent que le réseau a une capacité suffisante pour apprendre les caractéristiques discriminantes des gestes tout en restant compatible avec un entraînement sur des machines classiques.

L'optimiseur choisi est Adam, combiné à la fonction de perte categorical cross-entropy, adaptée à la classification multi-classes. Le modèle est entraîné sur des batches de taille 64, pendant 5 époques par itération de chargement de nouvelles images.

### 4. Prétraitement et encodage

Avant d'être introduites dans le modèle, les images subissent les étapes suivantes :

- Conversion en niveaux de gris, réduisant la complexité computationnelle
- Redimensionnement et mise en forme en tenseurs 3D (hauteur × largeur × 1 canal)
- Encodage des labels en vecteurs catégoriels (one-hot encoding) pour l'apprentissage supervisé

Ces étapes assurent une cohérence entre les données d'entraînement et celles utilisées en temps réel.

### 5. Implémentation pratique

Le modèle est implémenté en Python à l'aide des bibliothèques Keras et TensorFlow pour le deep learning, et OpenCV pour la capture et le traitement des images en temps réel.

Le pipeline d'utilisation en temps réel fonctionne ainsi :

1. La webcam capture l'image de la main.
2. Un cadre centré sur la main est défini, correspondant à la zone d'intérêt pour la prédiction.
3. L'image du cadre est convertie en niveaux de gris et mise en forme pour le modèle.
4. Le modèle CNN prédit la lettre correspondante.
5. La lettre prédite est affichée sur l'écran en temps réel.

Cette approche permet une interaction intuitive et immédiate avec le système, démontrant la faisabilité pratique de la reconnaissance des lettres de la langue des signes.

### 6. Schéma du pipeline

Le pipeline global peut être résumé ainsi :

***Acquisition d'images → Prétraitement → Encodage des labels → Entrée dans le CNN → Prédiction → Affichage en temps réel***

Chaque étape est optimisée pour garantir une reconnaissance rapide et précise des lettres tout en minimisant la charge computationnelle.

## 7. Conclusion

Ce chapitre a présenté l'architecture détaillée du modèle CNN et son implémentation, incluant les choix de couches, d'optimiseur, de fonction de perte et de prétraitement. Le système développé combine apprentissage profond et vision par ordinateur pour créer un modèle robuste capable de reconnaître les lettres de la langue des signes en temps réel. Cette base technique servira à l'évaluation des performances et à la discussion des résultats dans le chapitre suivant.

## V. Résultats et Discussion

### 1. Introduction

Ce chapitre présente les résultats obtenus après l'entraînement du modèle CNN pour la reconnaissance des lettres de la langue des signes, ainsi que leur interprétation. Il inclut l'évaluation quantitative à l'aide des métriques de loss et de précision, l'analyse qualitative des prédictions, et une discussion sur les limites du modèle et les perspectives d'amélioration.

### 2. Évaluation du modèle

Après l'entraînement, le modèle a été évalué sur un ensemble de test indépendant. L'évaluation a retourné les valeurs suivantes :

- Loss (fonction de perte) : 11,27
- Accuracy (précision globale) : 92,86 %

```
results
```

```
[11.268945693969727, 0.9285714030265808]
```

```
accuracy: 0.9286 - loss: 11.2689
```

Ces résultats indiquent que le modèle est capable de prédire correctement la majorité des lettres, même en présence de variations dans les images ou d'un éclairage différent. La loss relativement élevée peut s'expliquer par les différences dans certaines images de test et la complexité des gestes similaires.

L'accuracy proche de 93 % démontre que le réseau de neurones convolutionnel a appris des caractéristiques discriminantes efficaces pour les différentes classes, tout en conservant une capacité de généralisation satisfaisante.


### 3. Analyse qualitative

Une évaluation qualitative a été réalisée en utilisant la webcam pour tester le modèle en temps réel. Les observations principales sont :


- Les lettres distinctes sont reconnues avec une très bonne précision.
- Les lettres avec des gestes très proches, comme « M » et « N » ou « U » et « V », présentent parfois des confusions.
- L'interface temps réel permet d'afficher instantanément la lettre prédite sur l'écran.
- Le système est réactif et fluide, avec un délai minimal entre le geste et la prédiction.

### i. Prédiction de la lettre "A" en temps réel


La petite image située à droite (Frame 1) correspond à la région d'intérêt recadrée et prétraitée en niveaux de gris, utilisée comme entrée du modèle. L'image affichée à gauche (Frame 2) représente la frame complète issue de la webcam, incluant la zone de détection et le résultat de la prédiction. Le même principe de visualisation est adopté pour toutes les autres classes.




### ii. Prédiction de la lettre "B" en temps réel




**iii. Prédiction de la lettre “C” en temps réel**




**iv. Prédiction de la lettre “D” en temps réel**




**v. Prédiction de la lettre “E” en temps réel**




**vi. Prédiction de la lettre “F” en temps réel**




**vii. Prédiction de la lettre “G” en temps réel**




**viii. Prédiction de la lettre “H” en temps réel**




**ix. Prédiction de la lettre “I” en temps réel**




**x. Prédiction de la lettre “J” en temps réel**




**xi. Prédiction de la lettre “k” en temps réel**




**xii. Prédiction de la lettre “L” en temps réel**




**xiii. Prédiction de la lettre “M” en temps réel**




**xiv. Prédiction de la lettre “N” en temps réel**




**xv. Prédiction de la lettre “O” en temps réel**



**xvi. Prédiction de la lettre “P” en temps réel**




**xvii. Prédiction de la lettre “Q” en temps réel**




**xviii. Prédiction de la lettre “R” en temps réel**




**xix. Prédiction de la lettre “S” en temps réel**



**xx. Prédiction de la lettre “T” en temps réel**



**xxi. Prédiction de la lettre “U” en temps réel**




**xxii. Prédiction de la lettre “V” en temps réel**




**xxiii. Prédiction de la lettre “W” en temps réel**




**xxiv. Prédiction de la lettre "X" en temps réel**



**xxv. Prédiction de la lettre "Y" en temps réel**




**xxvi. Prédiction de la lettre "Z" en temps réel**




## xxvii. Prédiction de classes “spéciaux” en temps réel


- **Nothing (rien) :**



- **Del (delete = Supprimer) :**



- **Space (espace) :**



Ces images illustrent la capacité du modèle à fonctionner dans un environnement réel et rendent le rapport plus visuel et concret.

## 4. Limitations et difficultés rencontrées

Malgré la performance satisfaisante, certaines limitations ont été identifiées :

1. Qualité et diversité des images : certaines classes de lettres sont moins représentées dans le dataset ou capturées dans des conditions de luminosité différentes, ce qui peut affecter la précision.
2. Gestes similaires : certaines lettres ayant des gestes très proches peuvent être confondues par le modèle.
3. Temps de traitement : bien que rapide, le prétraitement en temps réel (redimensionnement, conversion en niveaux de gris) peut légèrement ralentir le système sur des machines peu performantes.
4. Absence d'augmentation de données : l'utilisation de transformations aléatoires (rotation, zoom, changement de luminosité) aurait pu améliorer la robustesse et réduire la loss.

## 5. Perspectives d'amélioration

Pour améliorer le système et sa précision, plusieurs axes peuvent être envisagés :

- Augmentation de données : appliquer des transformations sur les images d'entraînement pour rendre le modèle plus robuste aux variations de position et d'éclairage.
- Modèles plus profonds ou pré-entraînés : l'utilisation de réseaux pré-entraînés (transfer learning) pourrait améliorer la reconnaissance des gestes similaires.
- Détection multi-doigts et phrases complètes : étendre le modèle pour détecter plusieurs mains et traduire des phrases entières.
- Optimisation temps réel : réduire la taille du cadre ou optimiser les filtres pour accélérer la prédiction sur des machines moins puissantes.

## 6. Conclusion

Le modèle CNN développé a démontré sa capacité à reconnaître avec précision la majorité des lettres de la langue des signes américaine, avec une précision de 92,86 %. L'évaluation qualitative via la webcam confirme que le système est réactif et utilisable en temps réel.

Cependant, certaines limites liées aux gestes similaires et à la qualité des images suggèrent des pistes d'amélioration, telles que l'augmentation de données et l'optimisation du modèle.

# **Conclusion Générale**

Le projet de traduction de la langue des signes en texte à l'aide d'un modèle CNN a permis de concevoir un système capable de reconnaître automatiquement les lettres à partir de gestes manuels. En s'appuyant sur un dataset d'images de la langue des signes américaine, le modèle a appris à extraire des caractéristiques discriminantes et à prédire correctement la majorité des lettres. L'évaluation quantitative montre une précision de 92,86 % sur l'ensemble de test, confirmant la performance et la capacité de généralisation du réseau.

L'analyse qualitative en temps réel a démontré que le système pouvait fonctionner de manière fluide et réactive avec une webcam, offrant une interface intuitive pour la traduction instantanée. Les captures d'écran réalisées lors des tests illustrent l'efficacité du modèle et sa capacité à reconnaître des gestes variés dans des conditions d'éclairage et de position réalistes.

Cependant, certaines limitations ont été identifiées. Parmi celles-ci, la confusion entre lettres aux gestes très similaires, la variabilité dans la qualité et la diversité des images, ainsi que l'absence d'augmentation de données, peuvent limiter la robustesse du modèle. De plus, bien que le traitement en temps réel soit globalement satisfaisant, il peut être légèrement lent sur des machines moins performantes.

Pour aller plus loin, plusieurs axes d'amélioration peuvent être envisagés : l'augmentation des données d'entraînement via des transformations aléatoires, l'utilisation de modèles pré-entraînés plus profonds pour améliorer la précision, l'extension du système pour détecter plusieurs mains et traduire des phrases complètes, ainsi que l'optimisation du modèle pour accélérer le temps de prédiction. Ces améliorations permettraient de renforcer la robustesse et l'efficacité du système dans un contexte réel.

En conclusion, ce projet démontre la faisabilité et l'efficacité de l'utilisation des réseaux de neurones convolutionnels pour la traduction automatique de la langue des signes en texte. Les résultats obtenus constituent une base solide pour le développement de systèmes plus complets et performants, pouvant faciliter la communication pour les personnes utilisant la langue des signes.

# **Bibliographie**

## **Datataset :**

- ASL Alphabet Dataset. Kaggle. Disponible sur : <https://www.kaggle.com/grassknoted/asl-alphabet>

## **Sites Internet :**

- <https://www.keras.io>
- <https://www.tensorflow.org>
- <https://www.opencv.org>
- <https://www.numpy.org>
- <https://www.arxiv.org>
- <https://www.tutorialspoint.com>
- [https://openaccess.thecvf.com/content\\_cvpr\\_2018/papers/Camgoz\\_Neural\\_Sign\\_Language\\_CVPR\\_2018\\_paper.pdf](https://openaccess.thecvf.com/content_cvpr_2018/papers/Camgoz_Neural_Sign_Language_CVPR_2018_paper.pdf)

## **Cours / Supports académiques :**

- Vision par Ordinateur, Pr. Filali Hajar
- Deep Learning – Réseau de neurones avec deux couches cachées, Pr. Mounir Ait Kerroum
- Synthèse des Optimiseurs en Deep Learning, Pr. Mounir Ait Kerroum
- MATLAB Deep Learning With Machine Learning, Neural Networks and Artificial Intelligence – Phil Kim
- Neural Networks and Deep Learning, Michael Nielsen (the original online book can be found at <http://neuralnetworksanddeeplearning.com>)